



UNIVERSIDAD TÉCNICA
FEDERICO SANTA MARÍA

DEPARTAMENTO
DE INGENIERÍA
COMERCIAL

Análisis de compensaciones TalentCo

Curso: Analítica para Negocios 1

Profesor: Francisco Alfaro

Fecha: 29/05/2026

Integrantes: Nicolás Collao, Ignacio Ponce y Michelle Retamales

1. Contexto y objetivo del análisis

Primero se define el problema de negocio

Contexto: TalentCo necesita comprender por qué existen diferencias salariales entre sus empleados y qué variables explican de forma más relevante la compensación anual.

Pregunta central

¿Qué explica el salario?

Se busca identificar los factores más relevantes.

Enfoque

Regresión múltiple

Permite controlar varias variables al mismo tiempo.

Uso gerencial

Decidir mejor

Apoyo para política salarial y equidad interna.

- Variable dependiente: Salary, correspondiente al salario anual.
- Variables explicativas: experiencia, edad, desempeño, educación, área, región, nivel de cargo y género.
- El objetivo no es fijar sueldos automáticamente, sino entregar evidencia para decisiones de RR.HH.

2. Resultados principales del modelo final

Valores de regresión y entrenamiento

R² final entrenamiento

0,511

Explica 51,1% de la variabilidad salarial dentro de la muestra usada para estimar.

R² final prueba

0,494

Explica 49,4% en datos nuevos; evidencia de estabilidad fuera de muestra.

MAE prueba

7.596

error absoluto promedio

RMSE prueba

21.816

penaliza errores grandes

Modelo final

13 vars.

más simple que el modelo completo

La diferencia entre entrenamiento y prueba es baja. Por eso, el modelo final mantiene capacidad explicativa sin mostrar sobreajuste severo.

3. Datos y depuración resumida

La limpieza no es el foco, pero sostiene el análisis




Método principal de depuración: se eliminaron duplicados, se estandarizaron categorías, se imputaron faltantes con mediana en variables numéricas y moda en categóricas, y se winsorizó el salario entre percentiles 1 y 99.

La finalidad fue trabajar con una base consistente y comparable, reduciendo el efecto de errores de registro y valores extremos.

4. Lectura exploratoria del salario

Antes de modelar, se observan patrones esperados



Distribución: el salario se concentra entre 50.000 y 150.000 unidades anuales. La media final es cercana a 94.874 y la mediana a 91.732.

- El salario aumenta con experiencia y edad, aunque estas variables no explican todo por sí solas.
- El nivel de cargo muestra el patrón más claro: Senior supera a Mid y Junior.
- Engineering y Finance presentan salarios promedio superiores en el análisis descriptivo.

5. Modelo utilizado

Regresión lineal múltiple con variables numéricas y dummies

El modelo estima el salario anual controlando simultáneamente por factores personales, organizacionales y geográficos.

$$\text{Salary} = \beta_0 + \beta_1 \text{Experiencia} + \beta_2 \text{Edad} + \beta_3 \text{Desempeño} + \beta_4 \text{Cargo} + \beta_5 \text{Educación} + \beta_6 \text{Departamento} + \beta_7 \text{Región} + \beta_8 \text{Género} + \varepsilon$$

Entrenamiento
80%

8.002 observaciones

Prueba
20%


2.001 observaciones

Selección final
5%

variables significativas

6. Capacidad explicativa: R^2

Entrenamiento versus prueba




Interpretación: el modelo final explica 51,1% de la variabilidad salarial en entrenamiento y 49,4% en prueba.

En compensaciones, este desempeño es razonable: el salario depende también de factores no observados, como antigüedad, bonos, tipo de contrato, responsabilidades específicas y negociación individual.

Decisión: se prefiere el modelo final porque mantiene casi el mismo R^2 que el completo, pero con una estructura más simple.

7. Error de predicción

Qué tan lejos queda el modelo del salario observado



MAE test
7.596

desviación promedio absoluta


RMSE test
21.816

castiga más errores grandes

La diferencia train-test es baja, por lo que el modelo no parece depender de memorizar el conjunto de entrenamiento.

8. Coeficientes e interpretación

Qué variables pesan más en el salario



Resultado central: el nivel de cargo es el principal determinante. Subir un nivel se asocia con aproximadamente 20.160 unidades adicionales de salario anual.

- PhD y Master agregan primas salariales frente a Bachelor.
- La experiencia y el desempeño influyen positivamente, pero con menor magnitud.
- HR, Sales y Marketing muestran diferencias negativas frente al grupo base.

Estructura jerárquica
+20.160

cargo es el motor del salario

Capital humano
PhD +15.150

Master +7.272

Mérito
+1.088

por punto de desempeño

Departamentos
brechas

HR, Sales y Marketing bajo base

Género
+1.345

señal a auditar, no causalidad


Región
efectos

North positivo, South negativo

La principal recomendación es usar el modelo como apoyo para revisar bandas, consistencia interna y posibles brechas; no como una regla automática para pagar salarios.

10. Diagnóstico: multicolinealidad

Edad, experiencia y cargo están relacionados




Qué mide VIF: indica si una variable explicativa está muy relacionada con otras variables del modelo. Valores altos pueden dificultar aislar el efecto individual de cada coeficiente.

Resultado: Age tiene VIF 14,62, mientras que Job_Level y Years_Experience también son relevantes. Esto es esperable, porque edad, experiencia y nivel de cargo suelen avanzar juntos.

Decisión: el modelo puede usarse, pero la interpretación de estas variables debe ser cautelosa. No invalida el modelo, solo advierte que sus efectos se solapan parcialmente.

11. Diagnóstico: heterocedasticidad



Hipótesis nula: los errores tienen varianza constante.
Es decir, no hay evidencia de heterocedasticidad.

Resultados: Breusch-Pagan $p=0,374$; White LM $p=0,814$; White F $p=0,816$. Todos son mayores que 0,05.

Interpretación: no se rechaza la homocedasticidad.
Por lo tanto, no existe evidencia estadística suficiente de varianza no constante en los errores.

Sí, el modelo tiene sentido como herramienta explicativa y de apoyo gerencial. Explica cerca de la mitad de la variabilidad salarial, generaliza de manera estable y supera las pruebas principales de heterocedasticidad.

- R^2 de prueba cercano al de entrenamiento: no hay señales fuertes de sobreajuste.
- Errores MAE y RMSE son similares entre train y test: desempeño estable.
- Breusch-Pagan y White no detectan heterocedasticidad: la inferencia es más confiable.
- Errores robustos HC1 mantienen la significancia de variables clave: cargo, educación, experiencia y departamentos.

Límite clave: no debe usarse como única regla para fijar sueldos, porque no es causal y faltan variables relevantes como antigüedad, bonos, tipo de contrato y responsabilidades específicas.

1

Formalizar bandas salariales

Definir rangos por nivel Junior, Mid y Senior, con criterios de avance claros.

2

Revisar primas por educación

Validar si Master y PhD agregan valor real al cargo y documentar la política.

3

Fortalecer desempeño-compensación

Conectar evaluaciones con bonos, promociones o ajustes salariales.

4

Auditar brechas sensibles

Revisar diferencias por género, departamento y región con información adicional.

5

Mejorar datos de RR.HH.

Incorporar antigüedad, contrato, jornada, bonos, certificaciones y promociones.

El salario anual de TalentCo está asociado principalmente al nivel de cargo, educación, experiencia, desempeño, departamento, región y género. El nivel de cargo aparece como el factor más fuerte.

El modelo final es razonable para explicar patrones salariales y orientar decisiones, porque mantiene estabilidad en prueba y no presenta evidencia estadística de heterocedasticidad.

Mensaje final: el modelo no reemplaza el juicio gerencial, pero ayuda a construir una política de compensaciones más transparente, consistente y basada en evidencia.